

Leitfaden

MCP-Ansatz vs. Indexbasierte KI-Ansätze

Es gibt verschiedene Wege, um KI mit internem Wissen zu verbinden. Hier erfährst du Vor- und Nachteile.



EU Artificial
Intelligence Act



Made in
Germany



DSGVO
konform



amber ist Europas führende Business-KI.

Eine kompakte Business-KI, die internes Wissen effizient, sicher und DSGVO-konform zugänglich macht. amber kombiniert KI-Suche, Assistenzfunktionen und Automatisierung, um gezielte Antworten bereitzustellen – auf Basis deiner Unternehmensdaten und Zugriffsrechte. Mit über 70 Konnektoren (z. B. M365, Jira, Confluence) und Unterstützung für mehrere Sprachen ist amber flexibel einsetzbar. 100 % DSGVO- und ISO-27001-konform, ohne Kundendaten für Trainingszwecke zu nutzen. Deployment ist On-Premises oder in der Cloud möglich.



Mehr Fragen

Kontaktieren Sie uns unter
sales@ambersearch.de



Mehr erfahren

Jetzt [Termin vereinbaren](#)



Mehr Sehen

Produktvideos gibt
es auf [ambersearch.de](https://www.ambersearch.de)

Inhalt

Einleitung.....	3
Neue Zeiten brauchen neue Antworten	3
Evolution der unternehmensinternen Informationssuche	3
Kombination von unternehmensinternem Wissen & KI-Modellen.....	4
Technologische Ansätze zur KI-Integration im Unternehmen.....	5
FirmenGPT's ohne Integration	5
Native Suche via API-Calls (Federated Ansatz)	6
Schlagwortbasierte Suche (Indexbasiert)	7
Vektorbasierte Suche (Indexbasiert).....	8
MCP-Ansatz (Federated Ansatz)	9
Zusammenfassung	11
Der amber Ansatz.....	11

Einleitung

Immer mehr Unternehmen möchten KI einsetzen, da sie die potenziellen Mehrwerte sehen. Doch es gibt verschiedene Wege, um KI einzusetzen – z. B. Lösungen, welche komplett ohne Integrationen funktionieren oder Lösungen, welche mit einem Index oder via Model Context Protocol (MCP) funktionieren. In diesem White Paper klären wir auf, welche technischen Ansätze es gibt und welche Vor- bzw. Nachteile diese Systeme bieten.

Neue Zeiten brauchen neue Antworten

Die meisten Unternehmen setzen sich zunehmend mit KI auseinander, da die Geschwindigkeit des wirtschaftlichen Wandels heute höher ist als je zuvor. Um wettbewerbsfähig zu bleiben, suchen sie nach Lösungen, die ihnen helfen, sich an diese Dynamik anzupassen.

Gleichzeitig stehen viele Unternehmen vor einer großen Herausforderung: Über Jahre gewachsene IT-Infrastrukturen behindern effizientes Wachstum. Immer mehr Softwarelösungen, rasant wachsende Datenmengen und der demografische Wandel erschweren es, das intern vorhandene Wissen schnell und einfach zu nutzen. Dies macht deutlich, wie wichtig innovative Ansätze & die Wissenssicherung für das Fortbestehen vieler Unternehmen sind.

Evolution der unternehmensinternen Informationssuche

Die Suche in unternehmensinternen Informationen war schon immer ein Thema – sowohl im Analogen als auch im Digitalen. Seit der Erfindung von Datenbanken wurde es immer relevanter, interne Informationen zu finden – doch leider sind die meisten Lösungen dafür ausgelegt, Informationen sauber abzulegen und für bestimmte Automatisierungen bereitzuhalten – jedoch nicht, um Informationen einfach wieder zugänglich zu machen. Darum haben sich mit der Etablierung von Crawler und Indexansätzen nicht nur Suchanbieter für das Internet entwickelt sondern auch welche für Unternehmensinterne Inhalte.

Diese sogenannten Enterprise Search Anbieter haben zu der Zeit v. A. schlagwortbasierte (Keyword Search) Suchansätze verfolgt. Über die Zeit wurden diese Ansätze mit KI-Technologien wie Natural Language Processing so erweitert, dass auch anspruchsvollere Informationen gefunden werden konnten.

2017 wurde das wissenschaftliche Paper „Attention is all you need“ veröffentlicht, das die technologischen Konzepte für Sprachmodelle vorstellte und erstmalig eine semantische Suche – also das Finden auf Basis der inhaltlichen Bedeutung von Inhalten – ermöglichte. Mit einer reifer werdenden Technologie entschieden sich die Gründer von amber, zunächst

ihre unternehmensinterne Suchmaschine amberSearch zu entwickeln. Schon 2020 war den Gründern von amber klar, welches Potenzial in dieser Technologie steckt – weit bevor ChatGPT im November 2022 veröffentlicht wurde und ganz neue technologische Grundlagen schaffte.

Kombination von unternehmensinternem Wissen & KI-Modellen

Wer KI im Unternehmen einsetzen will, der muss keine KI-Modelle mit den eigenen Daten trainieren. Stattdessen wird auf einen technischen Ansatz, der sich Retrieval Augmented Generation (RAG) genannt, zurückgegriffen. Dieser funktioniert folgendermaßen:

1. Wissensbasis

Zunächst muss eine Wissensbasis definiert werden, auf welcher das System arbeitet. Diese Wissensbasis kann vorverarbeitet (indiziert) werden oder die Informationen werden in dem Zustand belassen, wie der Nutzer sie bereitstellt.

2. Retrieval (Suche)

Stellt ein Nutzer eine Frage, dann werden zunächst die passenden Informationen rausgesucht und priorisiert.

3. Augmentation

Diese Ergebnisse werden über einen Prompt an ein generatives KI-Modell übergeben. Dieser Prompt sieht in etwa folgendermaßen aus: „Der Nutzer hat Frage X gestellt, In Dokument 1, 2 und 3 befinden sich passende Inhalte. Nutze diese und generiere eine Antwort auf Basis der bereitgestellten Dokumente.“

4. Generierung

Die KI generiert eine Antwort auf Basis der bereitgestellten Dokumente.

Wer sich näher damit beschäftigt findet schnell heraus, dass zwar jeder es cool findet, wenn eine generative KI eine Antwort auf Basis der eigenen Inhalte generiert – die KI dafür aber Zugriff auf die richtigen Informationen haben muss.

Leider können aus Ressourcengründen und technischen Limitierungen (Context window) nicht alle Daten zeitgleich von einem KI-Modell verarbeitet werden, weshalb zunächst eine Suche in der Wissensbasis stattfinden muss. Nun ist es kein Problem auch für herkömmliche Ansätze wie einer Schlagwortsuche passende Treffer aus einem Wissensfundus aus z. B. ein paar Dutzend Dokumente zu finden. In der Praxis haben Unternehmen allerdings zig Millionen Dokumente, aus denen zunächst die richtigen Informationen rausgesucht werden müssen. **Werden also im Retrievalschritt nicht die richtigen Informationen gefunden, dann kann die KI in Schritt 4 auch keine guten Antworten generieren. Darum ist die Wahl des richtigen technischen Ansatzes und des Retrievals wichtiger als das ausgewählte generative KI-Modell.**

Im Folgenden werden in diesem White Paper werden die verschiedenen technischen Ansätze zur Integration von KI in Unternehmen erklärt.

Technologische Ansätze zur KI-Integration im Unternehmen

Wer KI im Unternehmen einsetzen möchte hat meistens schon Erfahrung mit KI – z. B. durch ChatGPT. Es fehlen jedoch einige wichtige Eigenschaften wie z. B. DSGVO-Konformität, konkrete Ansprechpartner oder Zugriffs- und Nutzerverwaltung, welche ChatGPT als Lösung für Unternehmen ausscheiden lassen. Daher suchen Unternehmen, welche ChatGPT aus dem Privaten kennen zunächst nach einem Firmen-ChatGPT. Damit wären wir schon beim ersten technischen Ansatz, um KI in Unternehmen zu integrieren:

FirmenGPTs ohne Integration

Aktuell gibt es diverse Agenturen und junge Anbieter, welche ein DSGVO-konformes ChatGPT anbieten – mit folgender Funktionsweise: Sie nehmen eine KI-Schnittstelle (API) von Azure (Microsoft's Cloud) auf denen die KI-Modelle von OpenAI (Hersteller von ChatGPT) DSGVO-konform betrieben werden. Zeitgleich bauen diese Anbieter eine neue Oberfläche, um die KI-Modelle nutzbar zu machen. Da diese Anbieter keine oder nur sehr rudimentäre Möglichkeiten bieten, interne Informationen anzubinden, gibt es zusätzlich die Möglichkeit, eigene Dokumente als Wissensbasis hochzuladen.

Vorteile	Nachteile
Schnell einsetzbar	Keine Berücksichtigung internes Wissen
Kein technischen Aufwände zur Einführung	Kommen schnell an technische Grenzen
Nutzerverwaltung vorhanden	Rudimentäre Konfigurationsmöglichkeiten
Upload des internen Wissens	Qualität oft nicht gut


Für kleine Anwendungsfälle mit geringen Datenmengen funktioniert dieser Ansatz insbesondere als Pilotprojekt sehr gut – er skaliert jedoch nur begrenzt gut, da solche Anbieter keinen Fokus auf ein qualitativ hochwertiges Retrieval legen.

In der Produktpalette von amber würde dieser Ansatz unserem Paket „Starter“ ([s. hier für Details](#)) entsprechen, wobei dort der Zugriff auf verschiedenste KI-Modelle ermöglicht wird, um eine Unabhängigkeit von spezifischen KI-Modellentwicklern zu garantieren. Letztendlich ist dieser Ansatz eine Möglichkeit, KI schnell und einfach ohne große Risiken einzusetzen und um Erfahrung zu sammeln. Andererseits merken viele Kunden schnell, dass die echten Mehrwerte erst kommen, wenn das interne Wissen ausreichend zugänglich ist. Dies führt zum nächsten technischen Ansatz – der Federated Search:

Native Suche via API-Calls (Federated Ansatz)

Eine Federated Search ist zunächst ein Ansatz, welcher ohne eigenen Index auskommt, aber dennoch das gesamte Wissen berücksichtigt. Es ist dabei die einfachste Form der Enterprise Search. So funktioniert eine Federated Search:

1. Zunächst wird eine Nutzeroberfläche entwickelt, über welche Nutzer eine Suche eingeben können.
2. Wenn ein Benutzer eine Suche eingibt, werden im Hintergrund die eingegebenen Wörter an die Suchalgorithmen aller angebotenen Systeme gegeben – also zum Beispiel die Laufwerkesuche, die Outlooksuche, usw. Jede Suchmaschine sucht mit der eigenen Logik im jeweiligen systeminternen Index.
3. Die von den jeweiligen Suchmaschinen gefundenen Ergebnisse werden an die Federated Enterprise Search wiedergegeben. Diese durchmischt die Ergebnisse nun nach einer eigenen Logik oder zeigt die Ergebnisse einfach sortiert nach den verschiedenen Datenquellen für den Nutzer an. ^



Dieser Ansatz war gerade in den 2000er und 2010er Jahren beliebt, um eine preiswerte Suchmöglichkeit mit technisch geringem Aufwand anbieten zu können, während man jedoch zeitgleich das gesamte Wissen berücksichtigte.


Vorteile	Nachteile
Einfache technische Integration	Abhängigkeit von Suchen der Hauptsysteme Mangelhafte Qualität API-Limitationen möglich Matching von Zugriffsrechten schwierig

Wer eine Federated Search im Einsatz hat, könnte nun die Ergebnisse an eine generative KI übergeben. Allerdings ist einer der größten Nachteile einer Federated Search, dass wenn zum Beispiel Laufwerke durchsucht werden und die Suche auf Laufwerken eine Minute dauert, diese Ergebnisse auch erst nach einer Minute an die generative KI übergeben werden können. Im alltäglichen Einsatz also keine echte Option, wenn man sich die heutigen Erwartungen der Nutzer ansieht. Darum gibt es einige Anbieter, die auch heute noch eine Suche auf einem keywordbasierten Ansatz anbieten:

Schlagwortbasierte Suche (Indexbasiert)

Die Schlagwortsuche basiert auf einem textbasierten Index, d. h. wenn ein Nutzer etwas sucht, wird jedes Wort durchsucht. Durch verschiedene [Natural Language Processing basierte \(NLP\) Funktionen](#) können Worte auch z. B. normalisiert werden. Dieser Ansatz ist ebenfalls in den 90er Jahren entstanden und wurde häufig als fortgeschrittenere Alternative zur Federated Search angewendet. Das Know-How liegt darin die Daten effizient zu indexieren und in hoher Geschwindigkeit abzufragen. Bewertungskriterien sind z. B. die Häufigkeit von Worten, wo sie vorkommen (Titel, Ordnerpfade oder normaler Text) sowie Aktualität des Dokuments.

Vorteile	Nachteile
Technik ist bewährt Filter und Facettenfunktionen möglich	Richtige Wörter müssen verwendet werden Keine Kontextberücksichtigung Manuelle Synonypflege Zugriffsrechte nicht immer berücksichtigt



In den letzten Jahren wurde – aufgrund der NLP-Funktionen – dieser Ansatz auch häufig als KI-Suche bezeichnet. Technisch ist dies korrekt, kann jedoch für Personen verwirrend sein, welche unter einer KI-Suche einen vektorbasierten Ansatz verstehen. Denn wo der schlagwortbasierte Ansatz jahrelang führend war (und auch in vielen Lösungen wie z. B. Laufwerken, Outlook & Co die dominierende Suchtechnologie ist) versteht man mittlerweile unter einer KI-Suche üblicherweise einen vektorbasierten Ansatz:

Vektorbasierte Suche (Indexbasiert)

Durch das bereits angesprochene Paper „Attention is all you need“ kamen große Transformer-Modelle auf den Markt. Große Transformer-Modelle sind in der Lage, Texte auf semantischer Ebene zu verstehen. Dies hat die Möglichkeit der Suche von Informationen grundlegend verändert. So funktioniert eine vektorbasierte Suche:


- **Indizierungsprozess**

Zunächst müssen die Informationen indiziert werden. Dafür werden die Informationen als Vektoren (alternativ: Embeddings) in einem Vektorindex abgespeichert. Dieser hat deutlich mehr als 3 Dimensionen. Um die Funktionsweise nachvollziehbar zu machen, verwenden wir folgende Analogie: Stellen wir uns vor, unser Index wäre ein dreidimensionaler Raum und die Tür wäre das Element, welches die Informationen von einer klassischen Textinformationen in einen Vektor verwandelt. Dann würde dieser Vektorengine z. B. alle Vektoren, welche eine Information zum Thema ESG speichern hinten, oben, rechts speichern. Alle Informationen zum Thema Maschinenbau vorne, unten, links. Das passiert mit allen Informationen, die grundsätzlich für die KI durchsuchbar sein sollen.

- **Suchprozess**

Sucht ein Mitarbeiter nun nach einer Information, dann wird die Suchanfrage ebenfalls in einen sogenannten Suchvektor umgewandelt. Dieser liegt also wiederum in unserem Vektorraum. Wird nun z. B. die Frage gestellt: „Welche ESG-Richtlinien muss ich im Maschinenbau?“ beachten, dann würde der Vektor in unserem Beispiel von hinten, oben, rechts nach vorne, unten links gehen. Die relevanten Ergebnisse sind diejenigen, die in der Nähe dieses Suchvektors sind. Das bedeutet, dass ich Informationen die z. B. oben, vorne, rechts im Raum liegen überhaupt nicht berücksichtige.

Der Vorteil dieses Ansatzes ist, dass man die Informationen nach eigenem Ermessen ablegen und suchen kann – d. h. man hat den ganzen Prozess in der Hand. Allerdings wird zeitgleich eine performante Indizierungspipeline ermöglicht, welche mit vielen unterschiedlichen Dateiformaten und großen Datenmengen umgehen kann. Dadurch, dass nur Vektoren in der Nähe des Suchvektors berücksichtigt werden, ist die Suche deutlich schneller als eine schlagwortbasierte Suche, da nicht alle Informationen durchsucht werden, sondern nur diejenigen, die eine bestimmte Nähe zum Suchvektor haben.



Vorteile	Nachteile
Semantische Verständnis von Informationen	Indizierung erfordert hohe Serverressourcen
Hohe Qualität der Suche	Technisch anspruchsvolle Umsetzung
Volle Kontrolle über Indizierung/Retrieval	


Seitdem Ende 2024 der Model Context Protocol Ansatz durch Anthropic vorgestellt wurde, gibt es einige Diskussionen, welcher Ansatz der technisch beste Ansatz ist. Darum betrachten wir im nächsten Schritt den MCP-Ansatz:

MCP-Ansatz (Federated Ansatz)

Beim MCP-Ansatz geht es im Grunde genommen darum, eine standardisierte Schnittstelle von einer KI-Anwendung zu einem externen System zu vereinfachen bzw. zu standardisieren. Dazu wird über die eigentliche Schnittstelle einer Anwendung (z. B. SharePoint) ein MCP-Server gesetzt, welcher die Anfrage der KI-Anwendung entgegennimmt. Der MCP-Server ist dann darauf spezialisiert, die richtige Information aus dem externen System abzufragen. Dafür macht er nicht nur eine Abfrage, sondern gleich mehrere, sequentiell hintereinander.

Ein Beispiel: Ein Mitarbeiter möchte wissen, welche ESG-Richtlinien im Maschinenbau relevant sind. Dann würde der MCP-Server eine erste Suchanfrage mit z. B. „ESG-

Richtlinien Maschinenbau“ an die Suche des angebundenen Systems schicken. Dann bekäme der MCP-Ergebnisse und würde auf dieser Basis die Suchanfrage anpassen – z. B. mit einem Datumsfilter usw. Das Ganze kann mehrere Iterationen benötigen – und dauert somit auch deutlich länger als eine Indexbasierte Suche.



Eine weitere Herausforderung ist, dass ein MCP-Server komplett abhängig von der Suchqualität der eigentlichen Suche des externen Systems ist. Somit handelt es sich bei dem MCP-Ansatz auch um einen Federated Ansatz. Letztendlich klingt und ist die Anbindung eines Systems an einen MCP ziemlich einfach – vorausgesetzt, dass externe System stellt einen MCP-Server bereit. Allerdings bedeutet dies nicht, dass die Qualität ebenfalls ausreichend ist. Zusätzlich könnten API-Beschränkungen (zum Beispiel nur X zugelassene Anfragen/Minute) zu Fehlern führen.

Vorteile	Nachteile
Einfache Anbindung	Erfolg hängt von Qualität der APIs ab
Flexibilität durch Anpassung Abfragen	Menge der Abfragen pro Query begrenzt
Fähigkeit, Aktionen zu triggern	Lange Suchlaufzeiten
Kein Index notwendig	Fehlende Konsistenz

Ein Vorteil des MCP-Ansatzes ist jedoch, dass darüber auch Aktionen ausgeführt werden können. Das bedeutet, Lösungen, welche MCP anwenden können zum Beispiel automatisch eine E-Mail versenden oder einen Wert in einem ERP oder CRM verändern. Damit lassen sich Anwendungsfälle automatisieren, welche vorher nicht automatisierbar waren.

Zusammenfassung

Über die Jahre haben sich verschiedene Ansätze entwickelt, wie Informationen aus verschiedenen Softwaresystemen abgefragt werden können.

Im Kern lassen sich diese auf Federated Ansätze sowie Indexbasierte Ansätze runterbrechen. Der Vorteil der Indexbasierten Ansätze ist, dass diese deutlich flexibler und qualitativ hochwertig sind, da die Entwickler komplette Kontrolle über Indizierungs- und Suchmechanismen haben. Federated Ansätze sind deutlich leichter zu implementieren, qualitativ, aber nicht so stark wie indexbasierte Ansätze.

Diese Suchansätze sind im Kern immer die Grundlage für moderne KI-Chatbots, welche bereits auf dem erwähnten Retrieval Augmented Generation-Ansatz aufsetzen. Der Vorteil von Retrieval Augmented Generation ist, dass ich keine eigenen KI-Modelle trainiere, da ich als Kontext für das generative KI-Modelle die passenden Treffer meiner Suche bereithalte. Die Aufgabe des generativen KI-Modells ist es dann nur noch, die bereits vorgefilterten Ergebnisse zusammenzufassen.

Für kleine Datensätze reichen simple Suchansätze oft aus. Doch für große Datenmengen, wo eine Suche in der Lage sein muss aus zig Millionen Datensätzen die 3-10 richtigen Dokumente herauszufiltern, wird die Qualität der Suche immer wichtiger. Daher gewinnen gerade im Roll Out und in der Skalierung auf unternehmensweite Anwendungsfälle indexbasierte Ansätze, weil die Qualität viel entscheidender ist, um gute Antworten zu generieren.

Der amber Ansatz

Bei amber haben wir bereits 2020 angefangen, eine KI-Suche auf Basis von Large Language Modellen zu entwickeln. Als der Hype um generative KI losging, hatten wir bereits eine stabile, funktionierende KI-Suche auf Basis der internen Daten. Im nächsten Schritt haben wir verschiedene, generative KI-Funktionen um unsere Suche herumgebaut. Dadurch haben wir eine sehr ausgereifte Suche, welche mit der großen Variabilität der Daten deutlich besser umgehen kann als Lösungen, welche in den letzten Jahren auf den Markt kamen und generative KI sowie die KI-Suche parallel entwickeln müssen.

Bei amber setzen wir auf eine Kombination der Ansätze – Wir nutzen z. B. den Indexansatz, um Datenmengen auf semantischer Basis zu durchsuchen, während wir einen MCP-Ansatz nutzen, um Aktionen in Drittsystemen zu ermöglichen.