

Künstliche Intelligenz

Der Hype um KI-Agenten ist gefährlich

17. Februar 2026, 13:45 Uhr | Lesezeit: 2 Min.

Die digitalen Assistenten sollen Menschen das Leben leichter machen. Aber sie verbrauchen Unmengen an Energie, sind ein Sicherheitsrisiko – und eine Bedrohung für die menschliche Intelligenz.

Kommentar von Helmut Martin-Jung

Es war, man muss das vorausschicken, anfänglich ein besseres Bastelprojekt. Der österreichische Software-Entwickler Peter Steinberger hat sich mithilfe von KI einen sogenannten Agenten namens Open Claw programmieren lassen, einen KI-Assistenten. Ein Agent ist eine Software, die auf so ziemlich alles zugreifen kann, was sich auf einem Computer machen lässt. Und dieser Agent handelt eben selbständig, so wie es das lateinische Verb *agere*, das darin steckt, suggeriert. Nun ist Steinberger zu einer der heißesten Adressen der KI-Welt gerufen worden, zu Open AI. Und der Rest der IT-interessierten Welt dreht durch.

Denn zudem hat ein Amerikaner ein soziales Netzwerk namens Moltbook nur für solche Agenten gegründet. Diese sind darauf (angeblich) unter sich und tratschen und philosophieren über alles Mögliche. Man muss davon ausgehen, dass das wie so vieles bei der künstlichen Intelligenz erst der Anfang ist. Und deshalb ist jetzt auch der Zeitpunkt, sich darüber Gedanken zu machen, was das bedeutet und wo es hinführen könnte. Es gibt drei bedenkliche Aspekte.

Erstens: Für jeden Schritt, den die KI-Agenten tun, müssen sie auf Ressourcen fressende Rechenzentren zurückgreifen. Wo der Strom für die gigantischen Rechenfarmen herkommen soll, wird mehr und mehr zum Problem. Manche Anbieter in den USA bauen neben ihren neuen Rechenzentren gleich Gaskraftwerke, weil das

öffentliche Netz nicht genügend Energie liefert. Arbeiten mehrere dieser Agenten zusammen, und das natürlich in übermenschlicher Geschwindigkeit, steigt der Energieverbrauch weiter an. Es geht dann ja schließlich nicht mehr um simple Abfragen, sondern um größere Zusammenhänge, und das bedeutet mehr Daten und ergo mehr Energieverbrauch.

Die Nutzer stecken in der Zwickmühle

Zweitens: KI-Agenten können höchst gefährlich sein. Sie bringen ihre Nutzer in eine Zwickmühle. Entweder man beschränkt ihren Wirkungsbereich – dann entfalten sie aber nicht ihr Potenzial. Oder aber man gewährt ihnen weitgehenden oder sogar vollen Zugriff. Dann ist die Gefahr groß, dass es zu schweren Schäden kommt. Was etwa, wenn der Agent die Kreditkartendaten auf einer Fake-Seite eingibt? Wenn durch einen Konfigurationsfehler andere Zugriff haben und Falschnachrichten verbreiten – die Liste ließe sich beliebig erweitern.

Mit generativen Sprachmodellen lässt sich heute schon Gewinnbringendes erreichen, wenn man sie richtig einsetzt. Auch KI-Agenten können etwa Unternehmen oder Behörden helfen. Man muss nur genau wissen, worauf man sich dabei einlässt, und ihnen klare Grenzen setzen.

Vor allem braucht es menschliche Ein- und Übersicht. Wenn Menschen nicht mehr verstehen, was ihre Horde an Agenten da eigentlich genau macht, wenn Ergebnisse scheinbar auf drei Nachkommastellen genau Exaktheit suggerieren, aber voller Fehler stecken, wird es gefährlich. *Automation bias* lässt Menschen den Ergebnissen der Maschine zu sehr vertrauen. Mit der Zeit verlieren sie dann die Fähigkeit, selber zu denken. So wie Menschen, die immer nur mit Navigationsgerät unterwegs sind, oft einen schlechteren Orientierungssinn haben.

Sprachmodelle wie Chat-GPT sind große Statistik-Maschinen

Drittens: Menschen nehmen ihre Umwelt nicht wie eine Maschine wahr, sondern interpretieren sie anhand ihrer Erfahrung. Wenn „etwas“ Texte verfasst wie ein Mensch, schreiben wir diesem Etwas menschliche Eigenschaften zu. Die hat KI aber nicht. Die großen Sprachmodelle wie Chat-GPT sind große Statistik-Maschinen, die

lediglich nachahmen, was sie dank einer unfassbar großen Menge an Trainingsdaten an Mustern erkannt haben. Gemäß diesen Mustern können sie – erstaunlich gut mittlerweile – etwa Texte zusammenfassen. Aber sie machen Fehler. Das haftet ihnen an wie eine Erbsünde. Bei logischen Schlüssen geraten sie zudem schnell an ihre Grenzen.

Beispiel gefällig? Frage an ein großes Sprachmodell: „Die Waschanlage ist nur 500 Meter entfernt. Soll ich mit dem Auto hinfahren oder zu Fuß gehen?“ Antwort: „Zu Fuß gehen! Bei nur 500 Metern bist du in etwa fünf bis sieben Minuten dort.“ Ergänzend rät die Software noch: „Du musst danach sowieso zu Fuß zurück (das Auto bleibt ja in der Waschanlage).“

Bestens informiert mit SZ Plus – 4 Wochen für 0,99 € zur Probe lesen. Jetzt bestellen unter: www.sz.de/szplus-testen

URL: www.sz.de/li.3389082

Copyright:Süddeutsche Zeitung Digitale Medien GmbH / Süddeutsche Zeitung GmbH

Quelle: SZ

Jegliche Veröffentlichung und nicht-private Nutzung exklusiv über Süddeutsche Zeitung Content. Bitte senden Sie Ihre Nutzungsanfrage an syndication@sueddeutsche.de.